

Base de Datos NoSQL

Dr. Federico DEL RAZO LÓPEZ

División de Estudios de Posgrado e Investigación
Instituto Tecnológico de Toluca / TecNM

Enero-2025

Outline

Introducción

Bases de Datos Relacionales

Bases de Datos NoSQL

- Bases de Datos Semiestructuradas

- Bases de Datos Orientadas a Documentos

Bases de Datos Orientadas a Grafos

Pirámide de Maslow




Figure 1: Necesidades Humanas (Sicología)

Conforme se satisfacen las necesidades más básicas, los seres humanos desarrollamos necesidades y deseos más elevados. (Maslow)


Pirámide DIKW ¹

Sabiduría: Encarnación del conocimiento y apreciación del **¿por qué?**

Conocimiento: Aplicación descriptiva de la información. Pueden responder a preguntas de tipo **¿cómo?** , abiertas o más complejas.

Información: Datos procesados. Pueden responder a preguntas de tipo: **¿qué, quién, cuando, dónde?**

Datos: Una colección de símbolos. No proporcionan respuestas.



¹[Jafari, 2022] Jafari, R. (2022). Hands-On Data Preprocessing in Python, Packt Publishing.

Un poco de historia

Inicialmente los **datos** eran empleados por las empresas en sus tareas cotidianas, sin ser procesados.

- En 1970 Edgar Frank Codd, de los laboratorios IBM, presentó el Modelo Relacional.



Modelo Relacional

Organiza los datos en forma de renglones y columnas (*tablas*), y mediante el uso del **álgebra relacional** y la **teoría de conjuntos**, permite realizar operaciones : selección, proyección, unión, intersección y diferencia, para **manipular** los datos almacenados en las tablas.

Un poco de historia ...

- Posteriormente las empresas se apoyaron en los **datos** para obtener **información** ².
- Se crean aplicaciones clasificadas bajo el término de **informática operacional**, privilegiando el desempeño de tareas repetitivas de: lectura, modificación, eliminación o actualización sobre los datos.

Aplicaciones operacionales

- Son capaces de dar una respuesta precisa a preguntas simples del tipo: ¿Quién?, Cómo?, Cuándo? ó Dónde?
- Desde la década de los **80's**, han sido soportadas por los *Sistemas de Gestión de Bases de Datos Relacionales (RDBMS)*.

²A diferencia de los **datos**, que por ellos mismos carecen de sentido, la **información** es definida como *information = data + meaning*

Un poco de historia ...

Motivados por diversas razones: *legales, seguridad, seguimiento de clientes o de mercados*, ... las empresas decidieron almacenar el conjunto histórico de sus datos en **repositorios**.

Pronto se dieron cuenta que estos repositorios contenían **conocimientos**³ potencialmente interesantes.

- En las décadas de los **80's y 90's** se empezaron a aplicar técnicas de minería de datos y aprendizaje automático para extraer patrones y conocimiento útiles.
- A mediados de la década de los 90's, se acuña del término **Minería de Datos**

³Knowledge

Un poco de historia ...

En la década del **2000**, la Inteligencia Artificial tuvo avances en áreas tales como:

- Aprendizaje profundo (Deep Learning)
- Reconocimiento de voz: *Siri de Apple, Alexa de Amazon, Google Assistant.*
- Robótica
- Procesamiento de Lenguaje Natural
- Visión por Computadora
- Juegos de mesa (La IA obtiene triunfos en Ajedrez y Go)

Un poco de historia ...

En la década del **2010**, se presentó una rápida expansión de la Inteligencia Artificial :

- Aprendizaje profundo y Redes Neuronales Profundas (capaces de aprender a partir de enormes bases de datos)
- Reconocimiento de voz y de imágenes, mejorando la identificación de objetos y la traducción automática de texto.
- Vehículos Autónomos
- Asistentes virtuales *Siri, Alexa, Google Assistant*.
- Procesamiento de Lenguaje Natural, la IA mejoró la capacidad de comprender y producir lenguaje natural.
- Robots con capacidades avanzadas de IA en la industria


¿...el presente ?

ChatGTP: *Un modelo de lenguaje de inteligencia artificial creado por OpenAI, que utiliza el aprendizaje profundo para generar respuestas a preguntas y realizar tareas de procesamiento de lenguaje natural. <https://chat.openai.com/chat>*



¿...y el futuro? ...

Preguntemos a **ChatGTP**:



The screenshot shows the ChatGPT web interface. The top bar includes a search icon, a tab for 'IA Advances in 2020s', a 'New chat' button, and a Google logo. The left sidebar contains a 'New chat' button, a list of previous conversations (one titled 'IA Advances in 2020s'), and options for 'Clear conversations', 'Upgrade to Plus', and 'Dark mode'. The main chat area shows a user prompt: 'Cuáles serán los avances de la IA en la década de los 2020?'. The AI response, generated by GPT-4, states it cannot predict the future with certainty but can mention some promising advances. It then lists two key trends: 1. Advances in deep learning, and 2. Increased data processing and storage capacity.

FD Cuáles serán los avances de la IA en la década de los 2020?

Como modelo de lenguaje entrenado por OpenAI, no tengo la capacidad de predecir el futuro con certeza. Sin embargo, puedo mencionar algunos de los avances más prometedores que se están desarrollando en el campo de la IA y que podrían tener un impacto significativo en la próxima década.

1. Avances en el aprendizaje profundo: El aprendizaje profundo es una técnica de inteligencia artificial que se basa en la construcción de redes neuronales artificiales capaces de aprender a partir de grandes cantidades de datos. Se espera que en la próxima década se produzcan avances significativos en esta técnica, lo que permitirá a las redes neuronales artificiales aprender de manera más rápida y eficiente, y mejorar su capacidad para reconocer patrones complejos en los datos.
2. Mayor capacidad de procesamiento y almacenamiento de datos: A medida que la tecnología avanza, se espera que la capacidad de procesamiento y almacenamiento de datos aumente significativamente en la próxima década. Esto permitirá a los sistemas de inteligencia artificial procesar y analizar grandes cantidades de datos de manera más rápida y eficiente, lo que a su vez mejorará la precisión de sus respuestas.

Regenerate response

[illegible]

Figure 2: Modelo Relacional (SQL)

Bases de Datos

Definición:

- Una colección compartida de datos lógicamente relacionados, junto con una descripción de estos datos, que están diseñados para satisfacer las necesidades de información de una organización.

Modelo Relacional (SQL) de bases de datos

- Es un modelo rígido (normalizado), dotado de una estructura predefinida.
- Presenta ciertos problemas para representar entidades del mundo real (e.g. datos faltantes o incompletos, atributos multi-valuados o de diferentes tipos *-heterogéneos-*)




Figure 3: Modelo Relacional (SQL)

Bases de Datos NoSQL


No Solo SQL (No Only SQL)

Son sistemas de gestión de bases de datos que utilizan modelos de datos flexibles que les permiten manejar grandes cantidades de datos **semi-estructurados** o **no-estructurados** (e.g. documentos, grafos, árboles, clave-valor, ...) organizados de manera que pueden ser escalados y distribuidos.

BD Semiestructuradas: XML


XML (*Extensible Markup Language*), es una alternativa para representar datos semi-estructurados, y se ha convertido en el formato universal para almacenar e intercambiar datos.

- $root(T)$
- $parent(u)$, $children(u)$, $ancestors(u)$, $descendants(u)$
- $siblings(u)$, $first(u)$, $last(u)$, $next(u)$



Ejemplo XML (w3schools)

```
1 <?xml version="1.0" encoding="UTF-8"?>
2 <bookstore>
3   <book category="cooking">
4     <title lang="en">Everyday Italian</title>
5     <author>Giada De Laurentiis</author>
6     <year>2005</year>
7     <price>30.00</price>
8   </book>
9 </bookstore>
```



XQuery, (w3schools)

```
1 <?xml version="1.0" encoding="UTF-8"?>
2 <bookstore>
3   <book category="cooking">
4     <title lang="en">Everyday Italian</title>
5     <author>Giada De Laurentiis</author>
6     <year>2005</year>
7     <price>30.00</price>
8   </book>
9 </bookstore>
```

Consultando con XQuery

```
1 for $x in doc("books.xml")/bookstore/book
2 where $x/price>30
3 order by $x/title
4 return $x/title
```

DOM, *Document Object Model* (w3schools)

```
1  ...
2  <p id="demo"></p>
3  <script>
4  var text, parser, xmlDoc;
5  text = "<bookstore><book>" +
6          "<title>Everyday Italian</title>" +
7          "<author>Giada De Laurentiis</author>" +
8          "<year>2005</year>" +
9          "</book></bookstore>";
10 parser = new DOMParser();
11 xmlDoc = parser.parseFromString(text, "text/xml");
12
13 document.getElementById("demo").innerHTML =
14 xmlDoc.getElementsByTagName("title")[0].childNodes[0].nodeValue;
15 </script>
```

DOM una interface que permite manipular documentos XML, escrita en diferentes lenguajes: C++, Java, Python, PHP, ...

Un ejemplo cotidiano de XML

```

Gas-Tecnologico.xml
UNREGISTERED


qScJ5nY4rGZiAEw4ToRxCw0oKdQGRcZg0JqEUCKTXXJm90phV90Iq5wBxpg0xYSVEY2iVVj+SNx0muLJGNXr5pWJqajM0j1
oKldahAA== SubTotal="692.28" Moneda="MXN" Total="800" TipoDeComprobante="I" MetodoPago="PUE"
LugarExpedicion="52140">
3  <cfdi:Emisor Nombre="SERVICIO MIRUSA S.A. DE C.V." Rfc="SMI070223982" RegimenFiscal="601" />
4  <cfdi:Receptor Nombre="TECNOLÓGICO NACIONAL DE MEXICO / INSTITUTO TECNOLÓGICO DE TOLUCA" Rfc=
  "TNM140723GFA" UsoCFDI="G03" />
5  <cfdi:Conceptos>
6    <cfdi:Concepto Cantidad="39.101" NoIdentificacion="PL/9469/EXP/ES/2015-10699729099"
      Descripcion="32011 MAGNA" Importe="692.28" Unidad="LITRO" ValorUnitario="
      17.7048" ClaveUnidad="LTR" ClaveProdServ="15101514">
7      <cfdi:Impuestos>
8        <cfdi:Traslados>
9          <cfdi:Traslado Importe="107.72" TipoFactor="Tasa" TasaCuota="0.160000" Impuesto="002
            " Base="673.25" />
10         </cfdi:Traslados>
11       </cfdi:Impuestos>
12     </cfdi:Concepto>
13   </cfdi:Conceptos>
14   <cfdi:Impuestos TotalImpuestosTrasladados="107.72">
15     <cfdi:Traslados>
16       <cfdi:Traslado Impuesto="002" TipoFactor="Tasa" TasaCuota="0.160000" Importe="107.72" />
17     </cfdi:Traslados>
18   </cfdi:Impuestos>
19   <cfdi:Complemento>
20     <tfd:TimbreFiscalDigital xmlns:tfd="http://www.sat.gob.mx/TimbreFiscalDigital" xsi:
      schemaLocation="http://www.sat.gob.mx/TimbreFiscalDigital http://www.sat.gob.mx/
      sitio_internet/cfd/TimbreFiscalDigital/TimbreFiscalDigitalv11.xsd" Version="1.1" UUID="
      74434991-4EA8-40B4-9064-0EA8FE1D484D" FechaTimbrado="2022-06-23T09:16:30" SelloCFD="
      fJx0Y8SV8fd9rJxcJJCi/Wz2miEh/tIFnb02Q3SdAcBxGk6B815ndyq7fuS2Zv8cpYt/j8hJJcAa0qdSsqAL+SqCKaL
      bqHJg+VoJkGMmQNLvvHfgBsrx0hkg0K6mNXS//YF+ry60tGBD9cWdV0PxcWgCQ3PWEGr0gLi9PoNos818tjQhE9Yq/
      oyY5RNk8sZX2B1PNfGLqHCTW6M/oyItoRXpJufxaZxvhrpSLk4Qwiyw90Ko30rCkMo7nL3Sqv8xFTp+6E4zZEW0QVc
  
```

Line 1, Column 1

Spaces: 2 XML

Base de Datos Relacional

Venta de Productos




Base de Datos Relacional + XML

Datos Estructurados
(Normalizados)



Datos Semi-Estructurados:



- La información puede ser intercambiada entre entidades independientes.
- La estructura de los documentos XML es auto-descriptiva
- La estructura XML puede ser extensible
- Se asegura un modelo de Base de Datos flexible, con crecimiento vertical y horizontal.

BD Semi-Estructuradas: JSON

JSON (*JavaScript Object Notation*), es un formato en texto, con una estructura auto-descriptiva ampliamente utilizado para almacenar e intercambiar datos.

```
1 {  
2   "nombre": "Juan",  
3   "edad": 30,  
4   "direccion": {  
5     "calle": "Calle 10",  
6     "ciudad": "CDMX",  
7     "codigoPostal": "12345",  
8   },  
9   "telefonos": [  
10    "7221234567",  
11    "1234567722"  
12  ]  
13 }
```

- Tiene una estructura jerárquica,
- Su estructura es auto-descriptiva,
- Es más corto que XML y es fácil de interpretar, ...

Bases de Datos Orientada a Documentos


MongoDB

Es una base de datos para almacenar y consultar o recuperar datos en un formato flexible que carece de un esquema (o estructura) predefinido.

Características:

- **Orientada a Documentos** Almacena los datos en un formato JSON.
- **Escalabilidad** Permite una escalabilidad horizontal para manejar grandes cantidades de datos de forma distribuida.
- **Indexación** Permite la creación de índices para incrementar la eficiencia de las consultas.
- **Agregación** Permite filtrar, proyectar, agrupar y manipular datos de manera flexible.
- ...

Base de Datos MongoDB



The screenshot shows a Jupyter Notebook interface with a file explorer on the left, a code editor in the center, and a terminal at the bottom.

File Explorer (Left):

- EXPLOREUR
- ÉDITEURS OUVERTS
- MONGODB
 - .ipynb_checkpoints
 - figures
 - NobelPrize
 - Countries.json
 - Country.json
 - Laurate.json
 - Laurates.json
 - Prize.json (selected)
 - Prizes.json
- STRUCTURE

Code Editor (Center):

File: Prize.json

```
NobelPrize > {} Prize.json > [] prizes > {} 4 > [] laureates > {} 1 > surname
1 {"prizes": [{"year": "2023", "category": "chemistry", "laureates": [{"id": "1029",
  "firstname": "Moungi", "surname": "Bawendi", "motivation": "\"for the discovery
  and synthesis of quantum dots\"", "share": "3"}, {"id": "1030",
  "firstname": "Louis", "surname": "Brus", "motivation": "\"for the discovery and
  synthesis of quantum dots\"", "share": "3"}, {"id": "1031", "firstname": "Aleksey",
  "surname": "Yekimov", "motivation": "\"for the discovery and synthesis of
  quantum dots\"", "share": "3"}]}, {"year": "2023", "category": "economics",
  "laureates": [{"id": "1034", "firstname": "Claudia", "surname": "Goldin",
  "motivation": "\"for having advanced our understanding of women\u2019s labour
  market outcomes\"", "share": "1"}]}, {"year": "2023", "category": "literature",
  "laureates": [{"id": "1032", "firstname": "Jon", "surname": "Fosse",
  "motivation": "\"for his innovative plays and prose which give voice to the
  unsayable\"", "share": "1"}]}, {"year": "2023", "category": "peace", "laureates":
  [{"id": "1033", "firstname": "Narges", "surname": "Mohammadi", "motivation": "\"for
```


Terminal (Bottom):

```
nobel> db.prizes.count_documents({})
TypeError: db.prizes.count_documents is not a function
nobel> db.countries.find({}, {'_id': 0, 'name': 1})
[
  { name: 'Algeria' },
  { name: 'Argentina' },
  { name: 'Australia' },
  { name: 'Austria' },
```

Status Bar (Bottom):

0 0 0 0 4 0 Select Postgres Server L 1, col 1425 Espaces : 3 UTF-8 LF JSON Go Live Spell Prettier

Base de Datos Relacional + XML + JSON



Bases de Datos Orientada a Grafos

MongoDB

Es una base de datos para almacenar y consultar o recuperar datos organizados como grafos.

Características:

- **Orientada a Grafos** Almacena los datos empleando un modelo de grafos.
- **Consultas** Emplea el lenguaje *Cypher* diseñado particularmente para trabajar con grafos.
- **Escalabilidad** Es escalable y apto para manejar grandes volúmenes de datos.
- ...

Base de Datos Orientada a Grafos Neo4j

neo4j@bolt://localhost:7687/neo4j - Neo4j Browser

neo4j\$

neo4j\$ MATCH p=(-[r:ACTED_IN]→()) RETURN p LIMIT 25

Node labels

(179) Movie Person

Relationship types

(258) ACTED_IN DIRECTED
FOLLOWS PRODUCED
REVIEWED WROTE

Property keys

born data id name
nodes rating relationships
released roles style
summary tagline title
visualisation

Connected as

Username: neo4j
Roles: admin, PUBLIC
Admin: server user list
server user add


Graph

Table

Text

Code

Use Cmd + scroll to zoom
Don't show again



Conclusión

Las bases de datos flexibles pueden ser creadas empleando modelos estructurados y no-estructurados

Continúa...